Máster Universitario en Bioinformática y Bioestadística 2026-2027

Propuesta de TFM y viabilidad del proyecto.

Marco Russo
IDP: 1 001 578
mrussorb@uoc.edu

Fecha de entrega:
29 de junio 2026

Universitat Oberta de Catalunya

Universitat de Barcelona

Índice

Resumen de la propuesta....3

2. Beneficios potenciales e impacto....4

3. Novedad y originalidad....4

4. Vinculación con la literatura — Estado del arte....5

5. Preguntas de investigación....6

6. Coherencia del diseño experimental....6

7. Limitaciones reconocidas....7

8. Planificación temporal (5 meses)*....7

9. Factibilidad (datos, tiempo y costes)....8

10. Consideraciones éticas y legales....8

12. Evaluación y gestión de riesgos....8

13. Prevención de plagio....9

Referencias bibliográficas....10

Resumen de la propuesta

¿Qué se hará?

Se implementará un pipeline bioinformático basado en Geometric Deep Learning para mapear el microentorno celular de la placa aterosclerótica humana con resolución espacial, condicionando el análisis por sexo biológico. La arquitectura central acopla una Graph Neural Network con atención (GAT) y condicionamiento FiLM con un Autoencoder Variacional Multimodal condicional (C-mVAE), aplicados sobre datos públicos de transcriptómica espacial (GEO: GSE233 025; Human Cell Atlas Heart).

¿Por qué debería hacerse?

La enfermedad cardiovascular causa ~18 millones de muertes anuales (OMS, 2023). Las mujeres presentan mecanismos fisiopatológicos distintos (erosión superficial de placa vs. ruptura en hombres) que los métodos tradicionales no capturan porque ignoran las interacciones de vecindad celular y no estratifican por sexo. Hartman et al. (Atherosclerosis, 2023) [13] concluyen explícitamente que los estudios futuros requieren análisis multi-ómicos sex-stratificados. Ningún trabajo publicado combina transcriptómica espacial cardiovascular + GNN + sexo como variable estructural: este TFM cubre ese vacío.

¿Cómo se hará?

Pipeline modular en cinco fases sobre datos públicos anonimizados*:

Fase 1 — QC y preprocesamiento: SpaceRanger + Squidpy sobre GSE233 025; deconvolución celular con SPOTlight [17].

Fase 2 — Baseline: STAGATE y SpaGCN como referencia comparativa (ARI/NMI/Silhouette).

Fase 3 — GNN sex-stratified: GAT + FiLM conditioning en PyTorch Geometric; C-mVAE con función de pérdida ZINB + KL + contrastive margin loss entre sexos.

Fase 4 — XAI: GNNExplainer (nivel local por spot) + SHAP/Captum (ranking global de genes por nicho).

Fase 5 — Integración y visualización: MOFA+ para integración epigenómica; dashboard interactivo en R Shiny/Streamlit.

* *las fases no están ni estimadas teniendo en cuenta que las tres primeras son mandatorias para la viabilidad de la investigación.*

2. Beneficios potenciales e impacto

El proyecto podría estar generando tres tipos de valor:

- **Valor científico**: Primer benchmark que aplica GNN sex-stratified + XAI espacial en ST de placa aterosclerótica, publicable en revistas Q1 (Briefings in Bioinformatics, Circulation Research).
- **Contribución clínica**: iIentificación de firmas génicas e interacciones celulares locales específicas de vulnerabilidad vascular en mujeres, abordando el infradiagnóstico cardiovascular femenino.
- **Impacto tecnológico**: Pipeline reproducible (Docker + GitHub Actions) y dashboard interactivo reutilizables por la comunidad; base algorítmica para futuras herramientas de estratificación de riesgo (potencial SaMD bajo MDR/AI Act 2024/1689). *

** no entra para el roadmap del TFM 2026-2027 del MU Bioinformática – Bioestadística.*

3. Novedad y originalidad

> *Sobre la contribución diferencial, la investigación no replica ninguno de los trabajos existentes. Las tres contribuciones diferenciales verificadas frente al estado del arte son:*

- **Contribución 1** — Primera GNN sex-stratified en ST cardiovascular. SpaGCN [6], STAGATE [5] y GraphST [7] han validado GNN en cerebro y cáncer, pero ninguno las ha aplicado a placa aterosclerótica ni incorpora sexo como variable estructural del grafo (FiLM conditioning), solo como filtro post-hoc si acaso.
- **Contribución 2** — Primera XAI espacial cardiovascular. El precedente más próximo de GNNExplainer + SHAP en tejido es Coskun et al. (BME Frontiers, 2025) [11] en cerebro. No existe ninguna aplicación en cardiovascular ni con estratificación de sexo.
- **Contribución 3** — Primera arquitectura C-mVAE condicionada por sexo en ST cardiovascular. Losert et al. (Nature Medicine, 2024) [9] aplicaron MOFA+ en síndrome coronario, pero sin capa espacial ST ni condicionamiento variacional por sexo. La arquitectura Product of Experts condicional propuesta es una extensión original del GVAE de Kipf & Welling (2016) [10].

4. Vinculación con la literatura — Estado del arte

Los trabajos más relevantes y sus limitaciones respecto a este TFM:

Estudio	ST Cardio.	GNN	Sexo	XAI	Año
Kanemaru (Nature)	✓ cor. sano	✗	✗	✗	2023
Campos (EMBO Mol. Med.)	✓ coronaria	✗	metadatos	✗	2025
Slenders (Nat. Commun.)	✓ carótida	✗	✗	✗	2024
Sukhavasi (Nat. CV Res.)	✗ scRNA	✗	✓ análisis	✗	2025
SpaGCN / STAGATE / GraphST	✗ cerebro/cáncer	✓	✗	✗	2021–23

Referencias adicionales que fundamentan el diseño: MOFA+ [8], Geometric Deep Learning [15], SPOTlight [17], directrices SAGER [14], revisión ML en ECV [12], revisión Deep Learning en ST [20].

5. Preguntas de investigación

> *Pregunta principal: ¿Existen nichos celulares espacialmente definidos en la placa aterosclerótica humana con programas transcripcionales específicos de sexo, identificables mediante una GNN sex-stratified con XAI sobre datos de transcriptómica espacial pública?*

Preguntas secundarias:

* **P1**: ¿Supera la arquitectura C-mVAE + GAT en delimitación de dominios tisulares (ARI) a los algoritmos no espaciales (STAGATE, SpaGCN, BayesSpace)?

* **P2:** ¿Qué ejes de comunicación ligando-receptor selecciona el mecanismo de atención como determinantes de la inestabilidad de la placa en pacientes femeninas?

* **P3:** ¿Puede la regularización topológica mitigar el dropout técnico sin inducir over-smoothing en poblaciones celulares minoritarias?

6. Coherencia del diseño experimental

Existe alineación estricta entre los datos disponibles y el análisis propuesto:

Tipo de datos	Dataset / Origen	Propósito en el modelo
Transcriptómica espacial	GEO GSE233025 (Campos, 2025)	Matriz expresión (X) + coordenadas para grafo (A)
Referencia celular sex-strat.	GEO GSE210572 (Sukhavasi, 2025)	Deconvolución SPOTlight por tipo celular y sexo
Validación cruzada	HCA Heart Visium (CZI)	Generalización a tejido cardíaco sano
Epigenómica (C-mVAE)	GTEx v10 + ENCODE ChIP-seq	Segunda modalidad para integración multiómica
Variable condicional (Y)	Metadatos fenotípicos del dataset	Sexo biológico como condicionamiento FiLM/C-mVAE

7. Limitaciones reconocidas

- Snapshot estático: los datos ST representan un instante del tejido; las relaciones celulares denotan correlación y proximidad, no causalidad dinámica.
- Resolución física (55 µm Visium): requiere deconvolución SPOTlight, que introduce incertidumbre; se mitigará con datos CosMx de Campos et al. si están disponibles en GEO.
- Tamaño de muestra por sexo: posible desequilibrio entre muestras femeninas y masculinas; se documentará exhaustivamente siguiendo directrices SAGER [14] y se aplicarán pesos de clase inversos.
- Validación prospectiva: fuera del alcance del TFM; los biomarcadores identificados requerirán validación experimental (inmunohistoquímica, qPCR) en estudios posteriores.
- Over-smoothing en poblaciones celulares minoritarias: riesgo inherente a GNN profundas; mitigado con skip connections y regularización topológica.

8. Planificación temporal (5 meses)*

Mes	Fase	Acciones clave	Entregable
1	Datos y QC	Descarga GSE233025 + HCA Heart; SpaceRanger; filtrado; deconvolución SPOTlight	Matrices QC, grafos construidos
2	Baseline GNN	STAGATE + SpaGCN; métricas ARI/NMI/Silhouette; benchmark inicial	Resultados baseline, UMAP
3	GNN sex-strat.	Implementación GAT+FiLM en PyG; entrenamiento C-mVAE; Optuna hyperopt	Modelo entrenado, curvas de loss
4	XAI + MOFA+	GNNExplainer + SHAP/Captum; integración epigenómica MOFA+; biomarcadores	Mapas de calor XAI, lista biomarcadores
5	Memoria + defensa	App Shiny/Streamlit; redacción TFM; defensa; preprint bioRxiv (opcional)	Memoria final, app, defensa

** A falta de realizar unas estimaciones y planificación detalladas de las tareas con Gantt.*

9. Factibilidad (datos, tiempo y costes)

- Acceso a datos: todos los datasets son públicos y de acceso libre inmediato (GEO, Human Cell Atlas, GTEx, ENCODE). No se requiere aprobación adicional. Acceso institucionales.
- Coste total estimado: xx–xx € (Google Colab + GPU / TPU); alternativa Kaggle Notebooks (30 h GPU/semana). AWS + GCP Cloud
- ...

10. Consideraciones éticas y legales

- RGPD / LOPDGDD: análisis secundario de datos públicos anonimizados; no requiere validación de comité ético en primera instancia.
- Directrices SAGER [14]: distinción explícita sexo biológico (genómico, usado en el modelo) vs. género (social, no disponible); reporte desagregado por sexo; análisis de sesgo algorítmico (Equalized Odds, Calibration gap).
- AI Act europeo (Reglamento EU 2024/1689): el modelo tiene potencial clasificación futura como SaMD de alto riesgo (Anexo III). En la fase TFM se adoptarán buenas prácticas: model card completo, reproducibilidad total (Docker), sin presentación como herramienta clínica directa.

12. Evaluación y gestión de riesgos

Riesgo	Prob.	Plan de contingencia
No convergencia arquitectura conjunta	Media	Desacoplar entrenamiento: primero VAE, luego GNN con embeddings estáticos como features de entrada
Datos CosMx no disponibles en GEO	Baja	Usar exclusivamente Visium + deconvolución SPOTlight
Desequilibrio de sexo en los datasets	Media	Pesos de clase inversos; documentación SAGER exhaustiva

Discontinuidad física (necrosis/calcificación)	Baja-Media	Función de coste Gromov-Wasserstein para alineamiento topológico global
Tiempo de entrenamiento excesivo	Baja	NeighborLoader (PyG) + sub-muestreo de grafos; Colab Pro A100

13. Prevención de plagio

Se adoptarán las siguientes medidas para garantizar la integridad académica:

- El documento final se someterá a los filtros institucionales anti-plagio de la UOC y la UB (Turnitin) antes de la entrega.
- Todo el código fuente desarrollado será original y se publicará en un repositorio GitHub con licencia abierta (MIT), incluyendo historial de commits que acredita el desarrollo propio.
- Las referencias a metodologías externas (STAGATE, SpaGCN, MOFA+, SPOTlight) se citan explícitamente [5, 6, 7, 8, 17] y se usan únicamente como baseline o herramienta de apoyo, no como núcleo de contribución.
- La contribución diferencial (GAT+FiLM sex-stratified, C-mVAE condicionado por sexo, XAI cardiovascular) es implementación y diseño propios, sin reproducción de código ajeno.

Referencias bibliográficas

[1] Sukhavasi, K. et al. (2025). Single-cell RNA sequencing reveals sex differences in the subcellular composition and associated gene-regulatory network activity of human carotid plaques. Nature Cardiovascular Research, 4, 412–432.

[2] Campos, J. et al. (2025). Spatial transcriptomics elucidates localized immune responses in atherosclerotic coronary artery. EMBO Molecular Medicine, 17(10), 2827–2846.

[3] Slenders, L. et al. (2024). Single cell spatial transcriptomics integration deciphers the morphological heterogeneity of atherosclerotic carotid arteries. Nature Communications.

[4] Kanemaru, K. et al. (2023). Spatially resolved multiomics of human cardiac niches. Nature, 619, 801–810.

[5] Dong, K. & Zhang, S. (2022). Deciphering spatial domains from spatially resolved transcriptomics with an adaptive graph attention auto-encoder. Nature Communications, 13, 1739.

[6] Hu, J. et al. (2021). SpaGCN: Integrating gene expression, spatial location and histology to identify spatial domains and spatially variable genes by graph convolutional network. Nature Methods, 18, 1342–1351.

[7] Long, Y. et al. (2023). Spatially informed clustering, integration, and deconvolution of spatial transcriptomics with GraphST. Nature Methods, 20, 1053–1063.

[8] Argelaguet, R. et al. (2020). MOFA+: a statistical framework for comprehensive integration of multi-modal single-cell data. Genome Biology, 21(1), 111.

[9] Losert, C. et al. (2024). Multiomic analyses uncover immunological signatures in acute and chronic coronary syndromes. Nature Medicine.

[10] Kipf, T. & Welling, M. (2016). Variational Graph Auto-Encoders. arXiv:1611.07308.

[11] Coskun, A. et al. (2025). Graph-Based 3-Dimensional Spatial Gene Neighborhood Networks of Single Cells in Gels and Tissues. BME Frontiers.

[12] Ahmed, Z. et al. (2024). Multimodal AI/ML for discovering novel biomarkers and predicting disease using multi-omics profiles of patients with cardiovascular diseases. Scientific Reports, 14, 26 503.

[13] Hartman, R.J.G. et al. (2023). Sex differences in the genetic and molecular mechanisms of coronary artery disease. Atherosclerosis.

[14] Heidari, S. et al. (2016). Sex and Gender Equity in Research: rationale for the SAGER guidelines and recommended use. Research Integrity and Peer Review, 1(1), 2.

[15] Bronstein, M. et al. (2021). Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges. arXiv:2104.13478.

[16] Kuppe, C. et al. (2022). Spatial multi-omic map of human myocardial infarction. Nature, 608, 766–777.

[17] Elosua-Bayes, M. et al. (2021). SPOTlight: seeded NMF regression to deconvolute spatial transcriptomics spots with single-cell transcriptomes. Nucleic Acids Research, 49, e50.

[18] Reif, A. et al. (2025). Consideration of sex/gender aspects in cardiovascular clinical trials. BMC Cardiovascular Disorders.

[19] Liu, H. et al. (2025). Marker Gene-Guided Graph Neural Networks for Enhanced Spatial Transcriptomics Clustering. AI Medicine, 2(1), 1.

[20] Wang, Z. et al. (2025). Integrating Spatial Omics and Deep Learning: systematic review. PMC12 561 129.